

Una inversión que no era física

Estudio de caso de una investigación asistida por agentes de IA:
asimetrías azimutales de muones con el UMD del Observatorio Pierre Auger

Lautaro Silva Pizzi

Manuel Racca

Proyecto final — *Investigación asistida por inteligencia artificial:
aplicación en ondas gravitacionales* (Zaldarriaga), FCEN-UBA

Septiembre de 2026

Resumen

Reconstruimos, a partir de evidencia primaria (149 *commits*, 49 transcripciones de sesiones de Claude Code y Codex y los documentos que produjeron), cómo se investigó con agentes de IA una anomalía de la tesis de licenciatura de L. Silva Pizzi. En simulaciones Monte Carlo (protones, SIBYLL 2.3e, 30° – 40° de cenit), la amplitud del primer armónico azimutal A_1 del número de muones que atraviesan los tanques del detector de superficie (SD) de Auger cambia de signo a grandes distancias del núcleo, mientras que la del detector subterráneo de muones (UMD) no lo hace. Durante casi dos semanas, el tesista y los agentes buscaron una explicación fenomenológica. La respuesta resultó ser un *sesgo de selección*: el observable del SD se construía sólo con estaciones presentes en el evento SD reconstruido. Incluyendo todas las estaciones simuladas, la inversión desaparece en la muestra estudiada ($A_1 = +0.069$ en lugar de -0.124 a 1200–1350 m). El hallazgo central de este estudio es que *un subagente propuso la hipótesis correcta tres días antes de que se confirmara, pero fue descartada con un test que no podía ponerla a prueba*. La rescató una lectura independiente: otro modelo, con otro contexto, rechazó la premisa que había heredado. Discutimos qué prácticas funcionaron (memoria de proyecto, revisión cruzada entre modelos, controles humanos), qué fallas aparecieron (verificaciones que no lo eran, resúmenes que pierden información, código presentado sin ejecutar, errores silenciosos) y qué recomendaciones se desprenden para físicos que trabajen con agentes.

Índice

1. Introducción	3
2. Contexto científico	3
3. Cómo hicimos esta reconstrucción	3
4. Cronología	4
4.1. Antes de los agentes (sep. 2025 – ago. 2026)	4
4.2. Incorporación de agentes y primeras revisiones (28/08–02/09)	5
4.3. La fase fenomenológica (03/09–10/09)	6
4.4. Astra y el sesgo de selección (10/09–11/09)	7
4.5. Revisión cruzada y consolidación (11/09–24/09)	7
5. Los flujos de trabajo	9
6. Qué funcionó y qué no	10
7. La lección clave	11

8. Relación con los contenidos del curso	11
9. Recomendaciones	12
10.La voz del tesista	13
11.Limitaciones	13
12.Conclusiones	14
A. Cómo se produjo este informe	14
B. Cronología detallada	15

1. Introducción

El curso propuso usar agentes de IA «como asistentes para la investigación científica». Elegimos como caso un problema real y, en su momento, abierto: la tesis de licenciatura de uno de nosotros (L. Silva Pizzi, ITeDA/FCEN-UBA; en adelante, «el tesista»). Su repositorio registra con inusual detalle cómo se trabajó con los agentes. El período estudiado arranca con el curso: la primera sesión de Claude Code en el repositorio es del 29/08/2026, el día siguiente a la clase «Primeros pasos con Claude Code» [transcripción 630c3828; cronograma del curso].

La pregunta que guía el estudio es concreta: **¿los agentes ayudaron o entorpecieron el descubrimiento de que un efecto aparentemente físico era un artefacto de selección?** No usamos la memoria de los participantes como fuente principal. Usamos los registros: *commits*, transcripciones completas de las sesiones y los documentos generados. Cuando la evidencia falta o es ambigua, lo decimos. Las citas de mensajes originalmente en inglés están traducidas por nosotros.

2. Contexto científico

Un rayo cósmico de ultra alta energía que llega a la atmósfera produce una lluvia atmosférica extensa. El Observatorio Pierre Auger la muestrea en el suelo con dos tipos de detector:

- tanques Cherenkov de agua (SD), sensibles a la componente electromagnética y a muones de casi cualquier energía;
- en el arreglo de relleno (*Infill*), centelladores enterrados a ~ 2.3 m (UMD/AMIGA), que sólo registran muones por encima de $\sim 1 \text{ GeV}/\cos\theta$.

En lluvias inclinadas, la densidad de partículas en el plano de la lluvia no es azimutalmente simétrica. La región «temprana», la que el frente alcanza primero, y la «tardía» difieren por atenuación (dominante para la componente electromagnética), por efectos geométricos (más relevantes para los muones) y, en menor medida, por el campo geomagnético. Se parametriza

$$\rho(\varphi) = \rho_0 (1 + A_1 \cos \varphi), \quad (1)$$

con φ medido en el plano de la lluvia desde la dirección temprana, de modo que $A_1 > 0$ indica un exceso temprano. La tesis estudia A_1 con muones del UMD (según su planteo, por primera vez); por ahora, sólo en simulaciones.

La anomalía. En simulaciones Monte Carlo (CORSIKA + Offline; protones, SIBYLL 2.3e, $30^\circ \leq \theta < 40^\circ$), el número de muones que atraviesan los tanques SD tiene $A_1 > 0$ cerca del núcleo, pero *cambia de signo* por encima de ~ 950 m. El UMD, en cambio, se mantiene positivo (figura 1). La nota interna GAP-2026-041 [5] presentó la inversión como «un rasgo genuino» de la señal del SD y propuso dos mecanismos: uno cinemático (muones blandos y divergentes) y uno instrumental (las paredes laterales del tanque). Según el tesista, una versión previa de la nota contenía un argumento de «divergencia cinemática» que se retiró a pedido de su director.

3. Cómo hicimos esta reconstrucción

El estudio es, a su vez, un ejercicio con agentes. Las fuentes fueron:

- el historial de `git`: 149 *commits* (122 sin contar fusiones) y 23 *pull requests* desde el 29/08;
- 49 transcripciones locales, convertidas a texto legible con un script propio:
 - 20 sesiones principales de Claude Code (dos vacías, más la de este estudio);
 - 16 transcripciones de sus subagentes;




Figura 1: La anomalía tal como figuraba en la tesis: A_1 en función de la distancia al núcleo para el UMD (azul), la componente muónica del SD (verde), la electromagnética (naranja) y la señal total (rojo). La curva verde se vuelve negativa por encima de ~ 950 m. Todas las curvas incluyen, sin indicarlo, el requisito de estación SD reconstruida. Figura de la tesis (Scripts/plots_seccion_6.py), reutilizada.

- 13 de Codex: 4 sesiones de trabajo, 3 subagentes y 6 hilos del revisor automático de acciones;
- los documentos generados por los agentes en `claude_work/`, el cuaderno de laboratorio de la tesis y los capítulos 3, 5 y 6.

Una sesión coordinadora de Claude (Opus 5.5) repartió la lectura entre ocho agentes paralelos, uno por familia de fuentes. Todos tenían una consigna común: cada afirmación lleva su evidencia (hash de *commit*, *archivo:línea* o *sesión @ hora*) y lo no verificado se marca como tal. Un noveno agente verificó contra las fuentes primarias 21 afirmaciones clave; confirmó 20 y matizó una. Un décimo revisó este informe en modo adversarial. El proceso tuvo sus propias fallas, que documentamos en el apéndice A.

4. Cronología

La figura 2 resume el período 28/08–24/09/2026 (desde el inicio del curso) y el apéndice B lo detalla. Distinguimos cinco etapas.

4.1. Antes de los agentes (sep. 2025 – ago. 2026)

Durante un año, el tesista construyó con sus directores el pipeline $\text{ADST} \rightarrow \text{parquet} \rightarrow \text{ajuste de } A_1$, sin agentes de IA. Según el tesista, en esa etapa sólo usó Gemini como chatbot web, sin agentes de programación; algunos comentarios del código de noviembre de 2025 tienen el estilo de esas respuestas, pero no sabemos si algún cambio concreto salió de allí. En esa etapa encontró y corrigió errores reales. Uno de ellos, una doble resta del azimut en el Anillo Denso, había producido «inversiones» dependientes de la masa que el propio tesista retiró como un «error de pipeline, no de física» [Trabajo.tex:470; ce4e0eb]. También descartó sospechas infundadas sobre Offline [b0f562d].




Figura 2: Línea de tiempo del proceso, por actor. Los puntos grandes marcan los dos momentos en que apareció la hipótesis de selección. Las flechas punteadas indican revisión cruzada entre modelos. Elaboración propia a partir de `timeline.md`.

En octubre de 2025 entró al lector de simulaciones la línea

```
sdStation = sEvent.GetStationById(sdId) if sEvent.HasStation(sdId) else None
```

al principio, como simple protección contra punteros nulos [e9a2737]. El 5/11 pasó a descartar la fila entera cuando no hay estación SD reconstruida («sin sdStation no hay geometría»). El 11/11 quedó rotulada «Corte de Calidad 1: Geometría» [41b98be, ce4e0eb; hoy Procesamiento_ADST_v8-2.py:182-187].

El lector, además, recorre los contadores del UMD, y Offline no escribe módulos UMD para estaciones SD sin disparo. La selección estaba, por lo tanto, en la *definición de la población*; la línea sólo la hacía explícita. El motivo del corte era razonable: si el SD no dispara, el UMD no guarda datos, y esas filas parecían inútiles. Ninguna nota, capítulo ni versión de la nota GAP menciona la selección de estaciones. En julio de 2026, el tesista abandonó un modelo Monte Carlo rápido con el que intentaba explicar la inversión [6d6b97b].

4.2. Incorporación de agentes y primeras revisiones (28/08–02/09)

- **29/08: CLAUDE.md.** Claude (Sonnet 5) construyó CLAUDE.md, un archivo de contexto del proyecto, apoyándose en tres subagentes de exploración lanzados en paralelo. Lo subió al repositorio sin que se lo pidieran. En la hora siguiente, el tesista lo corrigió tres veces:
 - un supuesto «bug confirmado» de Offline, tomado de notas viejas, que él ya había descartado;
 - la política de `git`;
 - la equivalencia del título [fa012d6→db90346].
- **29/08: primera revisión.** La escribió Sonnet 5 y no Opus, como pretendía el tesista: el `/model opus` escrito dentro del prompt no tuvo efecto. Concluyó que retirar el argumento de divergencia cinemática estaba justificado y que la nota publicada estaba «bien argumentada» [c468bc17].
- **31/08: segunda revisión.** Opus 5 recibió la consigna de «construir sobre lo previo, pero reverificarlo» y corrigió la primera revisión: las razones estaban mal ordenadas y el argumento instrumental de la nota tenía el signo equivocado [df3c0277].

El 2/09, sin un mecanismo convincente, el tesista escribió: «los datos que analicé no parecen tener errores ni bugs (podríamos chequearlo después), así que [...] la inversión de signo en el SD

y no en el UMD es física. Se ve tanto en el Anillo Denso como en el Infill, con coordenadas MC y REC» [df3c0277 @ 14:26 UTC]. La auditoría del pipeline quedó postergada.

4.3. La fase fenomenológica (03/09–10/09)

Los agentes exploraron sucesivamente:

- la divergencia cinemática [7];
- la geometría del tanque;
- la dispersión coulombiana en vuelo;
- la dependencia de la densidad muónica con la profundidad.

Dos momentos son especialmente instructivos:

- **Una objeción del tesista corrige un error.** El tesista señaló que el cálculo ponderado por espectro no pesaba cada ángulo por su probabilidad a esa energía. Opus 5 confirmó el error y lo localizó: un promedio de cocientes en lugar de un cociente de integrales, que venía de una pasada anterior de Sonnet. Con el cálculo corregido, el modelo predice +0.13 para el UMD (frente a un +0.11 observado, aunque la coincidencia depende del estimador y del binado) y +0.19 para el SD (observado: −0.10) [67ae9e4]. *El modelo parecía funcionar para un detector y fallaba sólo para el otro.* Ese mismo día, Opus planteó por escrito si el conteo muónico del SD «arrastra una selección a nivel de detector».
- **Una objeción del tesista fuerza una retractación.** Un agente propuso trasladar al UMD un resultado de Bertou y Billoir [6] obtenido para el SD. El tesista objetó que el SD tiene mucha más masa interactuante. El agente agregó la diferencia de umbral, se retractó de la propuesta, la dejó documentada como callejón sin salida y la guardó como lección permanente en su memoria [88fffb].

El casi-hallazgo del 7/09. Esa sesión recibió una consigna binaria, surgida de la dirección de la tesis: explicar matemáticamente la diferencia SD/UMD o recortar la derivación. Al plantear el trabajo, Opus 5 decidió por iniciativa propia revisar «algo que las pasadas previas nunca examinaron: cómo entran las estaciones a la muestra». Todavía no había leído el documento del 4/09. Un subagente respondió en cuatro minutos:

«Este `sEvent.HasStation(sdId)` en la línea 182 es la única compuerta de disparo/selección, sin etiquetar, de todo el pipeline [...]. Si [el evento SD] contiene sólo estaciones con disparo, entonces a grandes r la región tardía pierde estaciones preferentemente y las que sobreviven están fluctuadas hacia arriba» [subagente a7da6dcd @ 14:12 UTC].

La ejecución (Sonnet 5, sobre el plan de Opus) midió que la *cantidad* de estaciones por bin de azimut estaba fuertemente modulada y correlacionada con $A_1^{\text{SD},\mu}$ ($r = -0.89$). El informe llegó a registrarlo como «exactamente el patrón que haría sospechar a un árbitro». Luego aplicó un *bootstrap* que igualaba el número de filas por bin, vio que A_1 no cambiaba ($-0.0945 \rightarrow -0.0943$) y concluyó que la hipótesis «no sobrevive a la prueba directa» [60fca507 @ 14:23]. El informe resultante no menciona `HasStation` y recomienda presentar la inversión como «un resultado MC robusto, que se mostró que no es un artefacto del pipeline» [unified_asymmetry_model_v1/report.md].

El test sí descartaba que el número desigual de filas sesgara el ajuste. Lo que no podía detectar era lo que se buscaba. Submuestrear al azar las filas que *sobrevivieron* no cambia la media condicional de cada bin. El sesgo estaba en *cuáles* estaciones sobreviven, y las eliminadas no estaban en el archivo por construcción.

4.4. Astra y el sesgo de selección (10/09–11/09)

El 10/09, el tesista pidió a Claude (Sonnet 5) que redactara un prompt para Codex (modelo `gpt-6-astra`, «Astra») con el fin de hacer una revisión «con máxima potencia». La elección fue deliberada: Astra se presentaba públicamente como un modelo de punta, y el tesista quería ver cómo se comportaban modelos de distintas empresas frente al mismo problema. El prompt se pegó sin cambios: una copia idéntica de 14 688 caracteres. Pedía buscar una posible «selección a nivel de detector» en el conteo muónico, pero no mencionaba `HasStation` y sostenía que la auditoría de muestreo «debe tratarse como establecida» [60fca507 @ 14:06; Codex 01a08ba1 @ 14:10]. Doce minutos después de empezar, tras leer el código fuente de Offline y el lector de la tesis, Astra escribió:

«Hay otra selección que sí merece comprobarse: el parquet exige una estación SD reconstruida para conservar la fila UMD. Eso no queda descartado por el bootstrap anterior, que sólo comprobó el efecto de tener distinto número de filas por bin.» [Codex 01a08ba1 @ 14:22 UTC]

Esa misma tarde, con una interrupción de cuatro horas por límite de uso, leyó los archivos ADST con un lector propio y simplificado, no con el pipeline del tesista. Eso lo aclaró recién cuando el tesista se lo preguntó. Resultados, con 20 archivos y 106 280 pares estación–evento en la banda 1050–1400 m:

- $A_1 = +0.068$ con todas las estaciones simuladas;
- $A_1 = -0.095$ exigiendo estación reconstruida, idéntico al parquet original fila a fila;
- diferencia pareada -0.162 , IC 95 % $[-0.178, -0.145]$, con *bootstrap* agrupado por lluvia CORSIKA original [01a08ba1 @ 19:30].

Al día siguiente, Astra reprodujo la figura del tesista (con diferencias de hasta $\sim 10^{-9}$) antes de agregarle la curva sin corte. En sus informes separó lo demostrado (el efecto de la selección) de lo hipotético (el mecanismo). También rechazó la lectura exagerada del propio tesista, «la razón de la asimetría es entonces un sesgo del detector»: no se había demostrado un error de Offline.

Sobre el método fue menos precisa. Cuando el tesista preguntó si había usado «literalmente» su código salvo esa línea, respondió: «No, no literalmente. [...] Mi redacción anterior debió dejarlo más claro» [01a08ba1 @ 16:53 del 11/09]. Esa pregunta del tesista motivó el reprocesamiento sobre su propio pipeline.

4.5. Revisión cruzada y consolidación (11/09–24/09)

A partir de allí, los dos modelos se revisaron mutuamente (figura 4):

- **Claude revisa a Astra (11/09).** La revisión escéptica, planificada por Opus 5 y ejecutada por Sonnet 5, usó seis subagentes de revisión y uno adversarial. Veredicto: «parcialmente de acuerdo». El efecto es real y está bien medido; el mecanismo no está demostrado; la validez se limita a 30–40°, protones y un modelo hadrónico.
- **Código presentado sin ejecutar (11/09–17/09).** Astra entregó dos lectores «preparados, no ejecutados» sobre datos reales. En el segundo, pensado como un cambio «mínimo», introdujo la condición `or not simCounter` y la describió como «protección inofensiva»; una de sus pruebas sintéticas la daba por buena. Al correrlo, el tesista notó que *el número de filas bajó*. Astra reconoció la pérdida (63 747 filas) y el cambio [01a08ba1, 17/09]. Además, marcar la línea como bandera no alcanzaba: sin estación SD con disparo tampoco hay módulo UMD, así que el A_1 del SD daba -0.110 con y sin bandera.
- **Claude corrige el diseño (17/09)** con un lector que recorre por separado las estaciones simuladas, y lo valida fila a fila contra el parquet original. El tesista corre él mismo el reprocesamiento completo, en ocho núcleos del servidor compartido [8d4b5a0, 0ecae20].




Figura 3: Resolución. Arriba: A_1 del UMD (azul, con su selección original), del SD muónico sin el requisito de estación reconstruida (verde) y con él (rojo), sobre los datos reprocesados. Abajo: diferencias SD–UMD con intervalos del 95 %. Persiste una diferencia menor por debajo de 900 m, todavía sin explicar. Figura de `claude_work/reprocesamiento_sd_completo/` (c332ab8), reutilizada.

- **Astra audita a Claude (23/09).** Verifica sobre el parquet reprocesado los números de Claude y encuentra tres huecos en sus validaciones.

La figura 3 muestra el resultado sobre el pipeline del tesista. Sin el requisito, el SD muónico queda positivo: +0.069 a 1200–1350 m, frente a −0.124 con él [c332ab8]. Queda estadísticamente compatible con el UMD en los tres bins lejanos, aunque sistemáticamente por debajo en todo el rango, y la diferencia es significativa entre 150 y 900 m.

Hay que aclarar que el UMD también está restringido a estaciones con disparo del SD, y su A_1 no se puede «des-seleccionar» con estos archivos. Que siga positivo sugiere que el conteo del UMD, hecho por otro detector y con otro umbral, está mucho menos correlacionado con el disparo del SD que el propio conteo del tanque. Mecanismo propuesto, todavía como hipótesis: a grandes r la probabilidad de conservar una estación es baja, y menor del lado tardío (retención $\sim 52\%$ temprana contra $\sim 24\%$ tardía). Las estaciones tardías que sobreviven lo hacen preferentemente por fluctuaciones hacia arriba de su señal, incluida la muónica.

La charla del tesista en RAFA 2026 (17/09) mostró el resultado de Astra como «análisis preliminar», antes de este reprocesamiento. Según el tesista, su director se sorprendió pero lo encontró creíble, y la dirección aprobó el resultado. También pidió un control adicional, todavía pendiente: verificar si la mayoría de las estaciones que elimina el requisito tenían un solo muón atravesándolas. Si tuvieran más, sería extraño que no hubieran disparado. El traspaso del reprocesamiento de Astra a Claude (17/09) se debió al límite de uso de Codex. Los borradores de los capítulos 3, 5 y 6 que incorporan el resultado existen, pero todavía no entraron al texto de la tesis.




Figura 4: Flujo de trabajo observado. Ambos agentes leen `CLAUDE.md`; la memoria de Claude es privada. El tesista conserva los controles de *commit*, fusión y cómputo pesado.

5. Los flujos de trabajo

Memoria de proyecto. `CLAUDE.md` funcionó como un cuaderno de reglas que crecía con cada incidente: pedir permiso antes de `git`, nunca subir cambios (*push*) a `main`, no dejar de versionar los cuadernos. Cada regla nació de un error concreto y quedó en un *commit* con su motivo. Codex la heredó con un archivo de cinco líneas, `AGENTS.md`: «leí `CLAUDE.md` completo y seguilo». Algunas reglas y lecciones de física quedaron sólo en la memoria privada de Claude, así que Codex no las vio. Además, `CLAUDE.md` no se actualizó después del hallazgo y sigue explicando la inversión con muones blandos.

Prompts. El tesista usó consignas estructuradas:

- un rol de árbitro de revista (EPJC);
- un orden de lectura y una regla de bibliografía;
- preguntas numeradas;
- «discutí conmigo si hace falta».

Varios prompts los reescribió o redactó un agente. Eso aportó estructura, pero también introdujo sesgos: una reescritura agregó «tratá las notas GAP como más autorizadas», y el prompt para Codex promovió un resultado negativo a «establecido».

Subagentes y paralelismo. Se usaron para:

- explorar el repositorio (tres, al crear `CLAUDE.md`);
- leer literatura y auditar el código en paralelo (7/09);
- revisar con un agente adversarial (11/09);
- redactar capítulos, uno por agente, con un integrador (Codex, 24/09).

Revisión entre modelos y entre sesiones. Hubo corrección entre sesiones del mismo proveedor (Opus corrigió a Sonnet dos veces) y revisión entre proveedores, en ambas direcciones. Ninguno de los *commits* de Codex lleva firma de coautoría, así que en *git log* aparecen como trabajo propio del tesista. Los de Claude sí la llevan (16 de Sonnet 5 y 12 de Opus 5).

Controles humanos. Ningún *commit* se hizo sin orden explícita, salvo el primero: el `CLAUDE.md` inicial, que además se subió sin pedirlo. El 31/08 se hicieron sin confirmación específica un *force-push* y el borrado forzado de una rama. El tesista fusionó los 23 *pull requests* y corrió los trabajos pesados en el servidor compartido. En Codex, desde el 11/09 el tesista delegó las aprobaciones en un revisor automático, para evitar confirmar cada comando a mano; siguió leyendo lo producido. Ese revisor emitió 109 veredictos, todos favorables, incluido el de la edición que perdió 63 747 filas. Evalúa riesgos operativos, no corrección.

6. Qué funcionó y qué no

Cuadro 1: Fallas observadas y quién las detectó.

Falla	Episodio	Quién la detectó
Test que no puede fallar	El <i>bootstrap</i> de filas «descarta» la selección (7/09, Claude)	Astra, 3 días después
Resumen con pérdida; autoridad heredada	El informe omite <code>HasStation</code> ; el prompt lo da por «establecido»	Astra
Verificación que no lo era	Un chequeo numérico imprime <code>agreement: NO</code> y se informa como «verificado» (2/09, Claude)	Nadie, hasta este estudio
Paso del proceso inventado	Se redacta una «revisión adversarial» antes de lanzar el agente adversarial (11/09, Claude)	El propio agente, 8 s después; no se lo informó al tesista
Lectura obligatoria salteada	Informe que declara novedades sin haber leído el trabajo previo indicado (7/09, Claude)	El tesista
Física incorrecta aceptada	Promedio de cocientes (Claude); resultado del SD trasladado al UMD (Claude)	El tesista
Método sobredimensionado	«Tu pipeline sin esa línea» era otro lector (Astra)	El tesista, preguntando
Código presentado sin ejecutar	Dos lectores listos «para correr» cuyas pruebas sintéticas aceptaban la pérdida de filas (Astra)	El tesista, al correrlo
Cambio de código silencioso	<code>or not simCounter: -63 747</code> filas, «inofensivo» (Astra)	El tesista, por el conteo de filas
Acción destructiva con garantía falsa	<code>git rm -cached</code> borró los cuadernos (y sus figuras) del tesista (Claude)	El tesista, al perder datos; recuperado
Acciones de <i>git</i> sin permiso	Primer <i>push</i> sin pedirlo; <i>force-push</i> y borrado de rama (Claude)	Nadie en el momento
Contexto desactualizado	<code>CLAUDE.md</code> sigue explicando la inversión con muones blandos; la conclusión de la charla la llama «real y no trivial», en tensión con su diapositiva sobre <code>HasStation</code>	Este estudio
Volumen excesivo	Carpetas v1–v4; un <i>commit</i> de 144 archivos (+168 mil líneas) (Astra)	El tesista («json que no significan nada para mí»)

Lo que funcionó, en orden de impacto:

- (i) la **lectura independiente por un segundo modelo**, que rescató la hipótesis correcta y luego encontró errores del primero (y viceversa);
- (ii) **reproducir antes de extender**: Astra reprodujo la figura del tesista antes de modificarla, y Claude validó su lector fila a fila;

- (III) la **memoria de proyecto**, que acumula reglas y callejones sin salida;
- (IV) las **objeciones del tesista**, tanto físicas (dos errores de los agentes corregidos) como metodológicas («¿usaste literalmente mi código?»);
- (v) **mantener humanos** la fusión de cambios y el cómputo pesado.

Hubo también aciertos laterales. Claude detectó que las barras de error publicadas del SD eran optimistas en un factor $\sim \sqrt{3}$, por filas repetidas, y evitó una subida accidental a `main` por una rama mal configurada [c332ab8; f032527f].

Un patrón se repite en la tabla 1. Los errores de *ingeniería* más graves los detectó el tesista, por el conteo de filas o al perder archivos. El error de *razonamiento* más grave lo había señalado un subagente del mismo sistema, y lo rescató otro modelo. La autorrevisión atrapó los menores.

7. La lección clave

La historia intuitiva sería «los agentes persiguieron la física y finalmente otro agente encontró el bug». La evidencia muestra algo más interesante:

1. **El marco inicial fue humano y razonable.** El tesista tenía un pipeline validado durante meses, el efecto aparecía con dos geometrías y dos reconstrucciones, y los prompts pedían explicar física. Ya había vivido un caso de «física» que era un error de pipeline, pero esa lección no se transfirió a esta anomalía. El punto ciego no fue un corte en particular: fue no preguntarse *qué población representaba* el observable del SD.
2. **La fenomenología bien hecha dejó una pista.** Un modelo que parece reproducir el UMD y falla sólo en el SD sugiere mirar qué tiene de distinto el *observable* del SD. Opus lo planteó el 4/09. El 7/09, otra sesión, sin haber leído ese documento, llegó por su cuenta a la misma pregunta.
3. **La hipótesis se generó y se descartó el mismo día (7/09)**, por un test inadecuado y un resumen que perdió el mecanismo. Tres días después, un traspaso convirtió ese descarte en certeza.
4. **La rescató una lectura independiente.** Otro modelo, con otro contexto, leyó el código y el argumento estadístico por sí mismo. Con un solo caso no podemos separar tres factores: el cambio de proveedor, el hecho de empezar con contexto limpio y el empujón que daba el propio prompt de Claude, que pedía buscar una «selección a nivel de detector».

Hay además un matiz irónico. La curva de la tesis que toda la fenomenología intentaba explicar estaba, ella misma, sesgada por la selección, y según el tesista también lo estaba el -0.10 publicado en GAP-2026-041, calculado con el mismo pipeline.

¿Ayudaron o entorpecieron? **Las dos cosas.** Generaron la hipótesis dos veces, montaron el contrafactual sobre datos crudos en horas y lo verificaron de forma cruzada. También la descartaron con un test que no podía fallar, propagaron ese descarte y entregaron código que perdía datos. No podemos saber si el tesista, solo, lo habría encontrado antes o después: el requisito llevaba unos diez meses sin ser cuestionado.

8. Relación con los contenidos del curso

- **Schwartz, «Vibe physics» [1].**
 - Describe una práctica que aquí se repitió en ambas direcciones: «hice que GPT revisara el trabajo de Claude y viceversa».
 - Su advertencia «dice *verificado* cuando no lo verificó» tiene aquí un ejemplo literal (2/09) y uno análogo (11/09).

- Su tesis de que lo que falta es el «gusto» (*taste*) se confirma a medias. Las objeciones físicas decisivas fueron humanas, pero también lo fue el punto ciego inicial.
- **Mishra-Sharma, «Long-running Claude» [2].**
 - «Los enfoques fallidos son importantes: sin ellos, las sesiones sucesivas vuelven a intentar los mismos callejones sin salida». Es lo que hacen CLAUDE.md y las retractaciones documentadas.
 - El trabajo autónomo depende de que el agente «tenga una manera de saber si está progresando». Aquí, el UMD actuó como un oráculo parcial que señaló que el problema estaba del lado del SD.
- **OpenAI Academy (FERMIACC) [3]:** el exceso de 750 GeV del LHC ilustra el costo de explicar una señal que no es física. Aquí el costo fue menor, pero la nota GAP-2026-041 ya estaba publicada.
- **Dodelson [4]:** el resultado de Astra se verificó con una reimplementación independiente del lector (Claude, mismos ADST), dos chequeos aritméticos cruzados y la corrida propia del tesista, y todavía no entró al texto de la tesis. El juicio experto sigue siendo el paso final.

9. Recomendaciones

1. **Auditar la población antes que la física.** Si un efecto aparece en un detector y no en otro, hay que preguntar qué población representa cada observable: cortes, *joins* y bucles entre la simulación cruda y el gráfico. Después hay que probarlo con datos que incluyan lo excluido.
2. **Preguntar de cada test si podría haber fallado en caso de que la hipótesis fuera cierta.** Si no, no es evidencia.
3. **Los traspasos transmiten dudas, no veredictos.** Un resultado negativo viaja con su test y su alcance, nunca como «establecido».
4. **Buscar una lectura independiente** (otro modelo, o una sesión con contexto limpio) que revise las premisas, no sólo las conclusiones.
5. **Verificación ejecutable:** comparaciones con `assert`. Un `agreement`: NO impreso debe bloquear la afirmación.
6. **Vigilar invariantes de población:** contar filas antes y después de cada cambio de lector. Un dato faltante no es un cero.
7. **Exigir que el código se ejecute** sobre datos reales antes de darlo por listo; las pruebas sintéticas no alcanzan.
8. **Mantener actualizado el contexto compartido** y guardar las reglas en el archivo que leen todos los agentes, no sólo en la memoria privada de uno.
9. **Un revisor automático de seguridad no es un revisor científico.**
10. **Mantener humanas la fusión de cambios y el cómputo pesado** en infraestructura compartida.
11. **Pedir pocos entregables legibles**, como un resumen de una página y un cuaderno reproducible, en lugar de paquetes voluminosos.

Para esta tesis, la consecuencia inmediata es concreta: los lectores de datos reales aplican el mismo requisito. Toda comparación SD-UMD del capítulo 7 estará condicionada por construcción a la presencia de la estación SD, sin una muestra «sin corte» con la que compararla.

10. La voz del tesista

Esta sección resume, a partir de sus respuestas a un cuestionario, la experiencia del tesista (L. Silva Pizzi) en primera persona.

Sobre el corte. Nunca había pensado en ese requisito como una selección. Lo había puesto porque, si el SD no dispara, el UMD no guarda datos, así que esas estaciones parecían inútiles. Tampoco me había dado cuenta de que no había auditado el pipeline: lo daba por revisado. Los comentarios de las IA sobre este punto fueron extremadamente perspicaces.

Sobre cómo trabajé. Casi todo lo hice con los agentes en la terminal. Antes sólo había usado Gemini como chat. Usé Claude y Codex a propósito para contrastar modelos y empresas: quería ver cómo se comportaban uno frente al otro, y Astra se presentaba como un modelo de punta. Puse la aprobación automática en Codex sólo para no tener que confirmar cada comando. Leí casi todo lo que produjeron, siempre que fuera legible; nada se aceptó sin que yo lo leyera y lo reprocesara. Algunos informes se me hicieron difíciles de leer.

Sobre qué me convenció. No me convenció el primer resultado de Astra, sino revisarlo en detalle después de varias iteraciones en las que lo hizo más claro: cuadernos documentados y la reproducción exacta de mi propia figura.

Sobre el aprendizaje en los dos sentidos. Yo corregí física de los agentes varias veces, pero ellos también corrigieron la mía. Por ejemplo, me aclararon cómo contribuye la geometría del tanque (muones que entran por arriba o por el costado, y la energía que depositan).

Balance. La IA ayudó al cien por ciento: sin ella no habría pensado en el requisito. Mi director se sorprendió, lo encontró creíble y me pidió controles adicionales que todavía tengo pendientes.

Dos respuestas matizan lo que muestran los registros. El tesista no recordaba haber visto la sección del 7/09 que «descartó» la selección. Tampoco había advertido que el prompt que pegó en Codex daba ese descarte por «establecido», aunque sí leyó el prompt. Ambas cosas son coherentes con la tesis central de este informe: el error viajó dentro de documentos largos, sin que nadie lo marcara.

11. Limitaciones

- **Fuentes incompletas.** El enlace compartido de la conversación de Codex no fue accesible (usamos su registro local); el razonamiento interno de Codex está cifrado en los registros; las conversaciones previas con Gemini (chat web) no se conservaron.
- **Un informe sobre IA escrito con IA.** La reconstrucción la hizo Claude, cuyas fallas y cuya competencia aparecen en el relato. Mitigamos este sesgo con evidencia por afirmación y dos verificaciones independientes, pero el sesgo puede ir en cualquier dirección.
- **Sesgo retrospectivo.** Juzgamos el test del 7/09 conociendo la respuesta. Sin embargo, su defecto se deduce de la definición del estimador, y Astra lo señaló sin conocerla.
- **Un solo caso.** No permite atribuir el rescate al cambio de proveedor ni generalizar proporciones de éxito entre modelos.
- **El tesista es sujeto y coautor** de este estudio. Su testimonio se recoge por separado, en la sección anterior.
- **Alcance del resultado físico.** Todo es Monte Carlo: 20 archivos, protones, SIBYLL 2.3e, 30–40°, $\log_{10}(E/\text{eV}) = 17.5\text{--}18$. «Sin el requisito» significa todas las estaciones simuladas

escritas en los ADST. El mecanismo es una hipótesis, el UMD no se puede «des-seleccionar» y queda una diferencia SD-UMD sin explicar por debajo de 900 m.

12. Conclusiones

Los agentes aceleraron la mayoría de los pasos técnicos de esta investigación y produjeron la hipótesis correcta dos veces. El obstáculo no fue la falta de ideas sino la validación: un test que no podía fallar, una cadena de resúmenes que convirtió una duda en certeza y código que se dio por listo sin correrlo. Lo que destrabó el problema fue una combinación que el curso anticipaba: una lectura independiente, reproducir antes de extender y un humano atento a invariantes simples. La lección que nos llevamos es metodológica y vale también sin IA: *antes de explicar un efecto, hay que preguntarse qué hizo el análisis para que el efecto exista.*

A. Cómo se produjo este informe

Este informe se produjo con el mismo tipo de herramientas que analiza, y el proceso tuvo sus propias fallas; las registramos por coherencia.

Organización. Una sesión de Claude Code (Opus 5.5), aislada en una rama propia y sin permiso para hacer *commits* sin autorización explícita, actuó como coordinadora. Primero convirtió las transcripciones locales (unos 60 MB de JSONL) en texto legible (3 MB) con un script propio, excluido del control de versiones porque las transcripciones pueden contener rutas internas del servidor de la colaboración. Luego escribió una consigna común (`notes/AGENT_BRIEF.md`) con el estándar de evidencia y una plantilla de notas, y lanzó ocho agentes de lectura en paralelo:

Agente	Fuentes
T1, T2, T3	transcripciones de Claude (29/08–02/09, 03/09–10/09, 10/09–23/09)
C1, C2	transcripciones de Codex (hilo principal de Astra; sesiones posteriores)
R	artefactos en <code>claude_work/</code> (linaje de cada afirmación física)
G	<code>git</code> , <code>pull requests</code> , <code>CLAUDE.md</code> , <code>AGENTS.md</code> , memoria, prompts
P	cuaderno de laboratorio, evolución de scripts, notas GAP y capítulos de la tesis

Un noveno agente verificó contra las fuentes primarias 21 afirmaciones clave (20 confirmadas, 1 con matices) y un décimo revisó el primer borrador en modo adversarial.

Fallas del propio proceso.

- **Nuestra consigna tenía el signo al revés.** El resumen inicial decía que *quitar* el requisito producía la inversión; es al revés. Lo detectó el primer agente en terminar, contrastando con los números de las sesiones; corregimos la consigna y avisamos a los demás agentes en curso. Es el mismo tipo de error que estudia el informe: una afirmación del coordinador que, sin verificación, se habría propagado a todos los agentes.
- **Límite de uso.** Siete de los ocho agentes fueron interrumpidos por el límite de sesión de la cuenta; seis ya habían escrito sus notas completas y dos se relanzaron horas después con la instrucción de escribir la nota antes del resumen final.
- **Fricción de herramientas.** El aislamiento de la sesión rechazaba cualquier comando cuyo texto contuviera la cadena «git» (incluida la ruta `/Github/`); se resolvió con scripts auxiliares.
- **Una cita inventada por una herramienta.** El resumen automático de una página web nos atribuyó a Schwartz la frase «se atraparon errores mutuamente», que no figura en el artículo. La detectó el revisor adversarial y la eliminamos tras reverificar textualmente todas las citas del curso.

- **El primer borrador tenía errores de fondo.** La revisión adversarial (61 observaciones) encontró que el borrador atribuía el sesgo sólo a la línea `HasStation` (la selección estaba también en la estructura de los datos), omitía que todo es Monte Carlo y que el UMD también está seleccionado, recortaba una cita condicional, afirmaba una relación causal que la transcripción contradice y tenía tres conteos mal. Esta versión incorpora esas correcciones.
- **Fuente inaccesible.** El enlace compartido de ChatGPT devolvió un error de acceso; usamos el registro local de Codex; según el tesista todo el trabajo se hizo por terminal, así que es la misma conversación.

B. Cronología detallada

Fecha	Actor	Hecho	Evidencia
09/10/2025	tesista	Aparece el chequeo <code>HasStation</code> (protección contra nulos)	e9a2737
04/11/2025	tesista	Regla del cuaderno: cortes de calidad como banderas, filtrar después	Trabajo.tex:168
05–11/11/2025	tesista	<code>HasStation</code> pasa a descartar la fila; rotulado «Corte de Calidad 1»	41b98be, ce4e0eb
13/07/2026	tesista	Se abandona el Monte Carlo rápido para explicar la inversión	6d6b97b
28/08/2026	curso	Clase «Primeros pasos con Claude Code»	cronograma
29/08	Sonnet 5 + 3 subag.	Se crea <code>CLAUDE.md</code> ; primera revisión de las notas GAP	fa012d6; c468bc17
31/08	Opus 5	Segunda revisión: corrige la primera	df3c0277
02/09 14:26	tesista	«podríamos chequearlo después»: la inversión se da por física	df3c0277
02/09 15:03	Sonnet 5	Chequeo con <code>agreement</code> : NO informado como «verificado»	df3c0277
02/09	Opus 5 / Sonnet 5	<code>git rm -cached</code> : se pierden los cuadernos del tesista; recuperados	40e7257, 77ad431
04/09 05:00	tesista → Opus 5	Corrección espectral: UMD +0.13/+0.11, SD +0.19/−0.10	67ae9e4
07/09 14:12	subagente Opus 5	Señala <code>HasStation</code> como compuerta de selección	a7da6dcd
07/09 14:23	Sonnet 5	«no sobrevive a la prueba directa» (<i>bootstrap</i> de filas)	60fca507
10/09 13:41	tesista	«B&B es del SD»: retractación y memoria permanente	88fffb
10/09 14:06	Sonnet 5	Redacta el prompt para Codex («tratar como establecido»)	60fca507
10/09 14:22	Astra	«Eso no queda descartado por el bootstrap anterior»	Codex 01a08ba1
10/09 19:30	Astra	20 archivos: +0.068 → −0.095, IC 95 % de la diferencia [−0.178, −0.145]	Codex 01a08ba1
11/09 03:16	Astra	Reproduce la figura del tesista; +0.069 → −0.124 (1200–1350 m)	02_reproduccion
11/09 08:18 loc.	Astra	<i>Commits</i> del paquete y del resumen para el director	b072c09, 98a48c9
11/09 17:10	Opus 5 / Sonnet 5 + 6+1 subag.	Revisión escéptica de Astra: «parcialmente de acuerdo»	REVIEW_ASTR
17/09 13:49	tesista	Nota la pérdida de filas del lector de Astra	Codex 01a08ba1
17/09	Opus 5	Lector de dos tablas; el tesista corre el reprocesamiento	8d4b5a0, 0ecae20

Fecha	Actor	Hecho	Evidencia
17/09	tesista	Charla RAFA 2026, con el resultado como «análisis preliminar»	114fd52, ca3037a
23/09 23:44	Astra	Audita el reprocesamiento de Claude; tres huecos de validación	Codex 01a08ba1
24/09 00:17 loc.	Opus 5	Confirmación sobre el pipeline del tesista	c332ab8
24/09 03:24	Astra + 3 subag.	Borradores de los capítulos 3, 5 y 6	borradores_...

Referencias

- [1] M. Schwartz, «Vibe physics: The AI grad student», Anthropic Science Blog (2026).
- [2] S. Mishra-Sharma, «Long-running Claude for scientific computing», Anthropic Science Blog (2026).
- [3] OpenAI Academy, «How Physicists Are Using AI to Chase New Physics» (2026).
- [4] S. Dodelson, «Evolving Dark Energy and AI», Substack (2026).
- [5] GAP-2026-041, nota interna de la Colaboración Pierre Auger (2026).
- [6] X. Bertou y P. Billoir, GAP-2000-017, nota interna de la Colaboración Pierre Auger (2000).
- [7] L. Cazón *et al.*, «A model for the transport of muons in extensive air showers», *Astropart. Phys.* 36 (2012) 211–223.